

Метод максимального правдоподобия

Схема математической статистики

Выборка: x_1, \dots, x_n Параметр: θ

$\hat{\theta}$

$f_{\hat{\theta}}(t)$

Точность
оценки,
прогнозов

Как оценить

- Метод моментов
- Метод максимального правдоподобия

Союзники

Асимптотические
(при большом n)

- ЦПТ
- Дельта-метод

доверительные
интервалы

Ответы на
вопросы

проверка
гипотез

Хорошие свойства

- Несмещенная
- Состоятельная
- Эффективная

Точные

- Теорема Фишера
- $\chi_n^2, t_n, F_{n,k}$
- Ещё союзники!

Схема математической статистики

Выборка: x_1, \dots, x_n Параметр: θ

$\hat{\theta}$

$f_{\hat{\theta}}(t)$

Как оценить

- Метод моментов
- Метод максимального правдоподобия

Хорошие свойства

- Несмещенная
- Состоятельная
- Эффективная

Союзники

Асимптотические
(при большом n)

- ЦПТ
- Дельта-метод

Точные

- Теорема Фишера
- $\chi_n^2, t_n, F_{n,k}$
- Ещё союзники!

Точность
оценки,
прогнозов

доверительные
интервалы

Ответы на
вопросы
проверка
гипотез

План

- Что такое метод максимального правдоподобия
- Примеры для дискретных и непрерывных распределений
- Информация Фишера, почему это информация и откуда она берётся
- Тест отношения правдоподобий
- Многомерный дельта-метод

Правдоподобие

Правдоподобие (likelihood function) – вероятность получить наблюдаемую выборку при конкретном значении параметра

Оценка максимального правдоподобия – значение параметра, которое максимизирует правдоподобие

Правдоподобие



X

Выборка: x_1, \dots, x_n

Предположение: выборка пришла из распределения с плотностью $f(x | \theta)$.

Параметр θ (константа) мы не знаем и хотим оценить по выборке.

Правдоподобие

Правдоподобие выборки:

$$\begin{aligned} L(\theta \mid x_1, \dots, x_n) &= \mathbb{P}(x_1, \dots, x_n \mid \theta) = f(x_1, \dots, x_n \mid \theta) \\ &= f(x_1 \mid \theta) \cdot f(x_2 \mid \theta) \cdot \dots \cdot f(x_n \mid \theta) = \prod_{i=1}^n f(x_i \mid \theta) \end{aligned}$$

При разных значениях θ мы получаем большую или меньшую вероятность получить наблюдаемые данные

Если выполнено неравенство

$$L(\theta_1 \mid x_1, \dots, x_n) > L(\theta_2 \mid x_1, \dots, x_n)$$

значение параметра θ_1 называют "более правдоподобным"

Метод максимального правдоподобия

Метод максимального правдоподобия состоит в выборе в качестве оценки $\hat{\theta}$ значения, при котором правдоподобие достигает максимума:

$$L(\theta \mid x_1, \dots, x_n) = \prod_{i=1}^n f(x_i \mid \theta) \rightarrow \max_{\theta}$$

Оценка максимального правдоподобия
(maximum likelihood estimation):

$$\hat{\theta}^{MLE} = \operatorname{argmax}_{\theta} L(\theta \mid x_1, \dots, x_n)$$

Метод максимального правдоподобия

Максимизация функции $L(\theta)$ равносильна
максимизации функции $\ln L(\theta)$.

Метод максимального правдоподобия

С логарифмической функцией работать удобнее, поэтому правдоподобие обычно логарифмируют и ищут максимум:

$$\ln L(\theta \mid x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i \mid \theta) \rightarrow \max_{\theta}$$

Возьмём производную и приравняем её к нулю:

$$\frac{\partial \ln L}{\partial \theta} = \sum_{i=1}^n \frac{\partial \ln f(x_i \mid \theta)}{\partial \theta} = 0$$

Решив это уравнение, получим оценку максимального правдоподобия

Резюме

- Метод максимального правдоподобия заключается в максимизации вероятности получить наблюдаемые данные по неизвестным параметрам
- Возможны ситуации, в которых функция правдоподобия не ограничена и MLE не существует
- Возможны ситуации, в которых функция правдоподобия достигает глобального максимума для нескольких θ
- Метод нельзя использовать, если не выполнены условия регулярности (область зависит от параметра или функция не дифференцируема)

Дискретный пример

Пример: распределение Бернулли

$$X_i = \begin{cases} 1, \text{ если любит кофе} \\ 0, \text{ если не любит кофе} \end{cases}$$

X_i	0	1
$\mathbb{P}(X_i = k)$	$1 - p$	p

$$x_1 = 1, x_2 = 0, x_3 = 1, \dots, x_n = 0 \sim iid Bern(p)$$

Задача: найти ML-оценку для p

$$\begin{aligned} L(p \mid x_1, \dots, x_n) &= \mathbb{P}(x_1, \dots, x_n \mid p) = \\ &= \mathbb{P}(x_1 \mid p) \cdot \mathbb{P}(x_2 \mid p) \cdot \mathbb{P}(x_3 \mid p) \cdot \dots \cdot \mathbb{P}(x_n \mid p) = \\ &= p \cdot (1 - p) \cdot p \cdot \dots \cdot (1 - p) = \\ &= p^{\sum x_i} \cdot (1 - p)^{n - \sum x_i} \rightarrow \max_p \end{aligned}$$

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln p + (n - \sum x_i) \cdot \ln(1 - p) \rightarrow \max_p$$

Пример: распределение Бернулли

Прологарифмируем:

$$\ln L = \sum x_i \cdot \ln p + (n - \sum x_i) \cdot \ln(1 - p) \rightarrow \max_p$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial p} = \frac{\sum x_i}{p} - \frac{(n - \sum x_i)}{1 - p}$$

! Колпачки появляются
после приравнивания
к нулю

$$\frac{\sum x_i}{\hat{p}} - \frac{(n - \sum x_i)}{1 - \hat{p}} = 0$$

$$\sum x_i - \cancel{\hat{p} \cdot \sum x_i} = n \cdot \hat{p} - \cancel{\hat{p} \cdot \sum x_i}$$

$$\hat{p}^{ML} = \frac{1}{n} \sum x_i = \bar{x}$$

Непрерывный пример

Пример: нормальное распределение

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x-\mu)^2}{2\sigma^2}} \quad x_1, x_2, \dots, x_n \sim iid N(\mu, \sigma^2)$$

Задача: найти ML-оценку для μ и σ^2

$$\begin{aligned} L(\mu, \sigma^2 \mid x_1, \dots, x_n) &= f(x_1, \dots, x_n \mid \mu, \sigma^2) = \\ &= f(x_1 \mid \mu, \sigma^2) \cdot f(x_2 \mid \mu, \sigma^2) \cdot \dots \cdot f(x_n \mid \mu, \sigma^2) = \\ &= \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x_1-\mu)^2}{2\sigma^2}} \cdot \dots \cdot \frac{1}{\sqrt{2\pi}\sigma} \cdot e^{-\frac{(x_n-\mu)^2}{2\sigma^2}} = \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \cdot e^{-\frac{\sum (x_i-\mu)^2}{2\sigma^2}} \rightarrow \max_{\mu, \sigma^2} \end{aligned}$$

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} -\frac{1}{2\hat{\sigma}^2} \cdot (-2) \cdot \sum (x_i - \hat{\mu}) = 0 \\ -\frac{n}{2} \cdot \frac{1}{\hat{\sigma}^2} + \frac{1}{2\hat{\sigma}^4} \sum (x_i - \hat{\mu})^2 = 0 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} -\frac{1}{2\hat{\sigma}^2} \cdot (-2) \cdot \sum (x_i - \hat{\mu}) = 0 \\ -\frac{n}{2} \cdot \frac{1}{\hat{\sigma}^2} + \frac{1}{2\hat{\sigma}^4} \sum (x_i - \hat{\mu})^2 = 0 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum (x_i - \hat{\mu}) = 0 \\ -n + \frac{1}{\hat{\sigma}^2} \sum (x_i - \hat{\mu})^2 = 0 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum x_i = n \hat{\mu} & \hat{\mu}_{ML} = \bar{x} \\ -n + \frac{1}{\hat{\sigma}^2} \sum (x_i - \hat{\mu})^2 = 0 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum x_i = n \hat{\mu} & \hat{\mu}_{ML} = \bar{x} \\ -n + \frac{1}{\hat{\sigma}^2} \sum (x_i - \bar{x})^2 = 0 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum x_i = n \hat{\mu} & \hat{\mu}_{ML} = \bar{x} \\ \frac{1}{\hat{\sigma}^2} \sum (x_i - \bar{x})^2 = n \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum x_i = n \hat{\mu} & \hat{\mu}_{ML} = \bar{x} \\ \frac{1}{\hat{\sigma}^2} \sum (x_i - \bar{x})^2 = n & \hat{\sigma}_{ML}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 \end{cases}$$

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Возьмём производную:

$$\frac{\partial \ln L}{\partial \mu} = -\frac{1}{2\sigma^2} \cdot (-2) \cdot \sum (x_i - \mu)$$

$$\frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2} \cdot \frac{1}{\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2$$

$$\begin{cases} \sum x_i = n \hat{\mu} \\ \frac{1}{\hat{\sigma}^2} \sum (x_i - \bar{x})^2 = n \end{cases}$$

$$\begin{aligned} \hat{\mu}_{ML} &= \bar{x} \\ \hat{\sigma}_{ML}^2 &= \frac{1}{n} \sum (x_i - \bar{x})^2 \end{aligned}$$

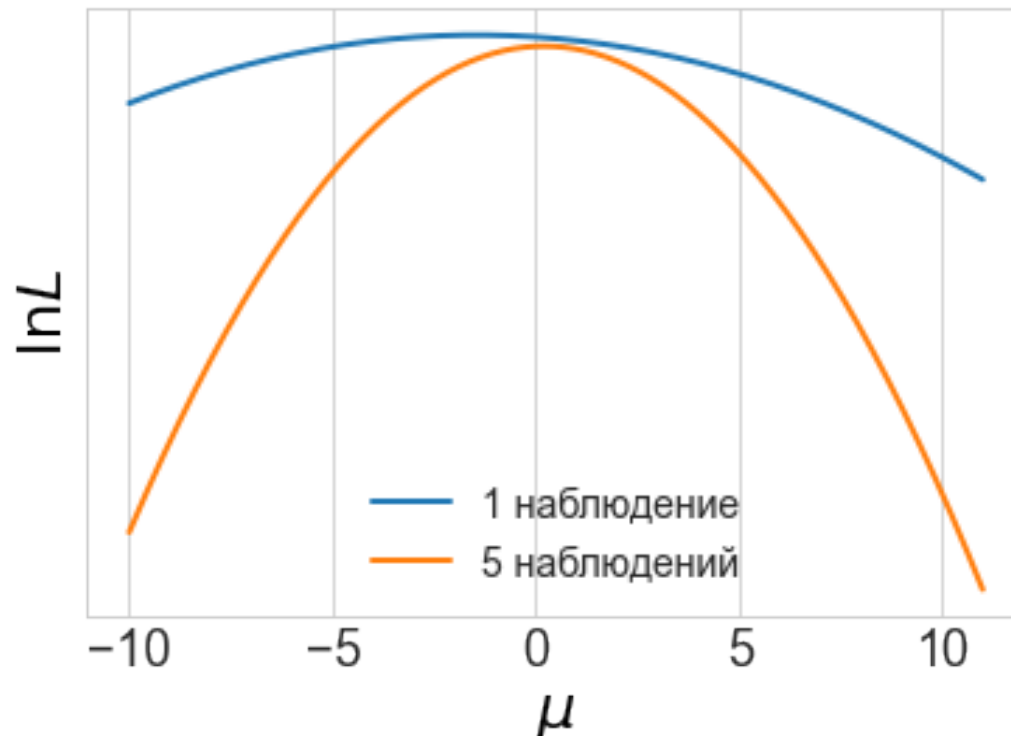
Информация Фишера

Точка максимума

- Одним из важнейших аспектов функции правдоподобия является её **поведение вблизи точки максимума**
- Если вблизи максимума функция достаточно плоская, то имеющиеся наблюдения **мало говорят о значениях параметров**
- Те же самые данные можно наблюдать с близкими вероятностями при разных значениях параметров
- Если функция имеет ярко выраженный пик, **данные имеют больше информации о параметрах**

Пример: $N(\mu, 1)$

- Для **красной** ситуации у нас мало информации, функция плоская
- Для **синей** ситуации у нас более яркий пик и более чёткая оценка




Накопление информации

Логарифм правдоподобия:

$$\ln L(\theta \mid x_1, \dots, x_n) = \sum_{i=1}^n \ln f(x_i \mid \theta)$$


- Одно слагаемое можно проинтерпретировать, как логарифм правдоподобия, вычисленный на основе одного наблюдения
- Дополнительные слагаемые дают информацию о том, как ведёт себя правдоподобие для новых наблюдений

Пример: $N(\mu, 1)$




- Логарифмическая функция правдоподобия **для всей выборки** складывается как **сумма** логарифмических правдоподобий **отдельных наблюдений**

Пример: $N(\mu, 1)$



- Она имеет **более выраженный максимум**, чем больше выборка, тем ярче выражен максимум

Пример: $N(\mu, 1)$



- Каждая лиловая линия – добавление к сумме нового слагаемого
- С каждым слагаемым максимум становится более выраженным
- Каждое слагаемое добавляет нам **информацию**

Информация Фишера

- Чем выпуклее функция, тем чётче выражен максимум
- За выпуклость функции отвечает вторая производная, именно её, взятую со знаком минус, интерпретируют как **наблюдаемую информацию (observed information)**

$$J_o(\theta) = -\frac{\partial^2 \ln L}{\partial \theta^2}$$

Информация Фишера

- Если параметр векторный, то наблюдаемая информация описывается матрицей из вторых производных (матрица Гессе)

$$J_o(\theta) = - \left(\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j} \right) = -H$$

Информация Фишера

- Математическое ожидание этой матрицы (по распределению наблюдений) называется **информационной матрицей Фишера**

$$J(\theta) = \mathbb{E}[J_o(\theta)] = -\mathbb{E}\left(\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j}\right) = -\mathbb{E}(H)$$

- ❗ Ожидаемая информация или ожидаемая “крутизна” функции правдоподобия

Информация Фишера

- Математическое ожидание этой матрицы (по распределению наблюдений) называется **информационной матрицей Фишера**

$$J(\theta) = \mathbb{E}[J_o(\theta)] = -\mathbb{E}\left(\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j}\right) = -\mathbb{E}(H)$$

- Наблюдаемая информация зависит **от конкретных значений наблюдений**
- Ожидаемая информация зависит **только от закона распределения наблюдений** и отражает, какую информацию вносит в правдоподобие среднестатистическое наблюдение

Неравенство Рао-Крамера

Если функция плотности $f(x_i | \theta)$ удовлетворяет условиям регулярности, тогда для любой несмещённой оценки $\hat{\theta}$ выполняется неравенство Рао-Крамера:

$$\text{Var}(\hat{\theta}) \geq [J(\theta)]^{-1}$$

А также имеет место равенство:

$$J(\theta) = -\mathbb{E} \left(\frac{\partial^2 \ln L}{\partial \theta_i \partial \theta_j} \right) = -\mathbb{E} \left(\left[\frac{\partial \ln L}{\partial \theta} \right] \cdot \left[\frac{\partial \ln L}{\partial \theta} \right]^T \right)$$

Этим свойством мы пользовались, когда проверяли оценки на эффективность

Свойства ML-оценок

1. **Состоятельность:** $\text{plim}_{n \rightarrow \infty} \hat{\theta} = \theta$

2. **Асимптотическая эффективность:**

$$\lim_{n \rightarrow \infty} \text{Var}(\hat{\theta}) = [J(\theta)]^{-1}$$

3. **Асимптотическая нормальность:**

$$\hat{\theta} \overset{asy}{\sim} N(\theta, [J(\theta)]^{-1})$$

4. **Инвариантность:** если $\hat{\theta}$ – ML-оценка для θ , тогда если $g(t)$ – непрерывная функция, то $g(\hat{\theta})$ – ML-оценка для $g(\theta)$

Асимптотическая нормальность

- ML-оценка асимптотически нормальна:

$$\hat{\theta} \sim N(\theta, [J(\theta)]^{-1})$$

- Это используют для строительства доверительных интервалов
- Нужно найти оценку для ковариационной матрицы (дисперсии) $[J(\theta)]^{-1}$

$$J(\theta) = -\mathbb{E}(H)$$

Пример: Нормальное распределение

Пример: нормальное распределение

Прологарифмируем:

$$\ln L = -\frac{n}{2} \cdot \ln 2\pi - \frac{n}{2} \cdot \ln \sigma^2 - \frac{1}{2\sigma^2} \sum (x_i - \mu)^2 \rightarrow \max_{\mu, \sigma^2}$$

Первые производные:

$$\begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \\ \frac{\partial \ln L}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (x_i - \mu)^2 \end{cases}$$

$$\hat{\mu}_{ML} = \bar{x}$$

$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$H = \begin{pmatrix} \frac{\partial^2 \ln L}{\partial \mu^2} & \frac{\partial^2 \ln L}{\partial \mu \partial \sigma^2} \\ \frac{\partial^2 \ln L}{\partial \sigma^2 \partial \mu} & \frac{\partial^2 \ln L}{\partial (\sigma^2)^2} \end{pmatrix}$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$H = \begin{pmatrix} -\frac{n}{\sigma^2} & -\frac{1}{\sigma^4} \sum (x_i - \mu) \\ -\frac{1}{\sigma^4} \sum (x_i - \mu) & -\frac{\sum (x_i - \mu)^2}{\sigma^6} + \frac{n}{2 \sigma^4} \end{pmatrix}$$

$\mathbb{E}(H) = ?$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$\mathbb{E}(H) = \begin{pmatrix} -\frac{n}{\sigma^2} & -\frac{1}{\sigma^4} \sum (x_i - \mu) \\ -\frac{1}{\sigma^4} \sum (x_i - \mu) & -\frac{\sum (x_i - \mu)^2}{\sigma^6} + \frac{n}{2 \sigma^4} \end{pmatrix}$$

$$\mathbb{E} \left(-\frac{n}{\sigma^2} \right) = -\frac{n}{\sigma^2}$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$\mathbb{E}(H) = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{\sum (x_i - \mu)^2}{\sigma^6} + \frac{n}{2 \sigma^4} \end{pmatrix}$$

$$\mathbb{E} \left(-\frac{1}{\sigma^4} \sum (x_i - \mu) \right) = \frac{1}{\sigma^4} \sum (\mathbb{E}(x_i) - \mu) = \frac{1}{\sigma^4} \sum (\mu - \mu) = 0$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$\mathbb{E}(H) = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{n}{2 \sigma^4} \end{pmatrix}$$

$$\mathbb{E} \left(-\frac{\sum (x_i - \mu)^2}{\sigma^6} + \frac{n}{2 \sigma^4} \right) = -\frac{n \cdot \sigma^2}{\sigma^6} + \frac{n}{2 \sigma^4} = -\frac{n}{2 \sigma^4}$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$\mathbb{E}(H) = \begin{pmatrix} -\frac{n}{\sigma^2} & 0 \\ 0 & -\frac{n}{2 \sigma^4} \end{pmatrix}$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$J(\theta) = - \mathbb{E}(H) = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2 \sigma^4} \end{pmatrix}$$

$$[J(\theta)]^{-1} = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2 \sigma^4} \end{pmatrix}^{-1} = \begin{pmatrix} \frac{\sigma^2}{n} & 0 \\ 0 & \frac{2 \sigma^4}{n} \end{pmatrix}$$

Пример: нормальное распределение

Первые производные:

$$\frac{\partial \ln L}{\partial \mu} = \frac{1}{\sigma^2} \cdot \sum (x_i - \mu) \quad \frac{\partial \ln L}{\partial \sigma^2} = \frac{\sum (x_i - \mu)^2}{2 \sigma^4} - \frac{n}{2 \sigma^2}$$

Вторые производные:

$$J(\theta) = - \mathbb{E}(H) = \begin{pmatrix} \frac{n}{\sigma^2} & 0 \\ 0 & \frac{n}{2 \sigma^4} \end{pmatrix}$$

$$\widehat{Var}(\hat{\theta}) = [\hat{j}(\theta)]^{-1} = \begin{pmatrix} \frac{\hat{\sigma}_{ML}^2}{n} & 0 \\ 0 & \frac{2 \hat{\sigma}_{ML}^4}{n} \end{pmatrix}$$

Пример: нормальное распределение

$$\hat{\mu}_{ML} = \bar{x}$$
$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum (x_i - \bar{x})^2$$

$$\begin{pmatrix} \hat{\mu}_{ML} \\ \hat{\sigma}_{ML}^2 \end{pmatrix} \underset{asy}{\sim} N \left[\begin{pmatrix} \mu \\ \sigma^2 \end{pmatrix}, \begin{pmatrix} \frac{\hat{\sigma}_{ML}^2}{n} & 0 \\ 0 & \frac{2 \hat{\sigma}_{ML}^4}{n} \end{pmatrix} \right]$$

Асимптотические доверительные интервалы:

$$\hat{\mu}_{ML} \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{\sigma}_{ML}^2}{n}} \qquad \hat{\sigma}_{ML}^2 \pm z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{2 \hat{\sigma}_{ML}^4}{n}}$$

Резюме

- В анализе данных производные обычно используются для передачи информации
- Информация Фишера вычисляется как матрица из вторых производных и говорит о “крутости” максимума
- Если функция $f(x_i | \theta)$ удовлетворяет условиям регулярности, ML-оценка обладает оптимальными свойствами в асимптотическом плане

Резюме


- ML-оценка имеет асимптотически нормальное распределение, для поиска её дисперсии используют информацию Фишера
- В “сложных” (нерегулярных) случаях ML-оценка может терять эти свойства

Тест отношения правдоподобий

Тест отношения правдоподобий

- Метод максимального правдоподобия очень широко распространён
- С помощью него можно проверять гипотезы


Тест отношения правдоподобий



$\ln L_{UR}$ — максимум логарифма правдоподобия
в модели без ограничений

$\ln L_R$ — максимум логарифма правдоподобия
в модели с ограничениями

Тест отношения правдоподобий



$$2 \cdot (\ln L_{UR} - \ln L_R) \underset{H_0}{\sim} \chi_q^2$$

q — количество ограничений вида $g(\theta) = 0$,
где g какая-то функция

Тест отношения правдоподобий

- H_0 : система из q ограничений на неизвестные параметры
- H_a : хотя бы одно из ограничений не выполняется
- Оцениваем модель без ограничений, находим $\ln L_{UR}$
- Оцениваем модель с ограничениями, находим $\ln L_R$
- Наблюдаемое значение статистики:

$$LR_{obs} = 2 \cdot (\ln L_{UR} - \ln L_R)$$

- Критическое значение статистики:

$$LR_{cr} = \chi_q^2 (1 - \alpha)$$

Тест отношения правдоподобий

- Тест отношения правдоподобий позволяет проверять гипотезы о различных ограничениях
- Внутри теста отношения правдоподобий может быть использовано сразу несколько ограничений \Rightarrow не нужно корректировать уровень значимости
- Для того, чтобы использовать этот тест, требуется вычислить максимум функции правдоподобия в модели без ограничений и в модели с ограничениями
- Тест отношения правдоподобий асимптотически оптимальный, т.е. обладает наименьшей ошибкой второго рода (наибольшей мощностью)